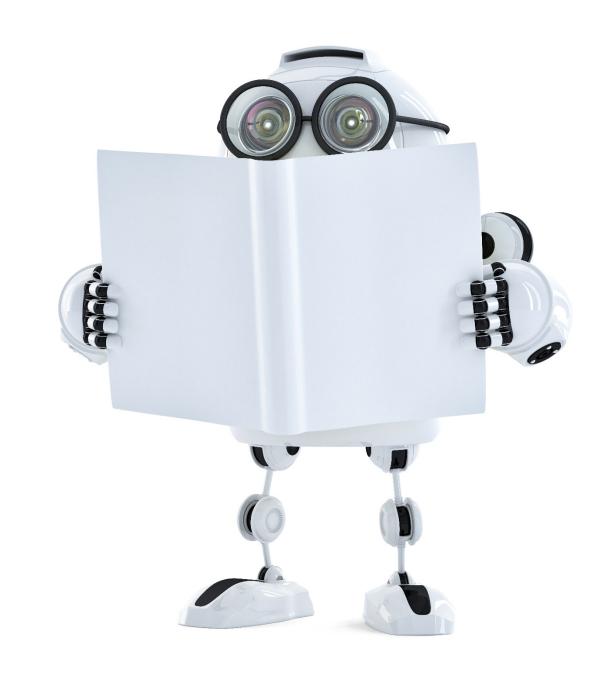
Visaulization

Director of TEAMLAB Sungchul Choi




우리의 데이터는 어떻게 생겼을까?

Visualization 데이터 시각화

파이썬의 대표적인 시각화 도구

matplitlib




다양한 graph 지원 Pandas 연동!

기본사용법

- pyplot 객체를 사용하여 데이터를 표시
- Pyplot 객체에 그래프들을 쌓은 다음 show로 flush

```
import matplotlib.pyplot as plt

X = range(100)
Y = [value**2 for value in X]
plt.plot(X, Y)
plt.show()
```



- 최대 단점 argument를 kwargs 받음,
- 고정된 argument가 없어서 alt+tab으로 확인이 어려움


```
Signature: plt.plot(*args, **kwargs)
Docstring:
Plot lines and/or markers to the
:class: `~matplotlib.axes.Axes`. *args* is a variable length
argument, allowing for multiple *x*, *y* pairs with an
optional format string. For example, each of the following is
legal::
   plot(x, y) # plot x and y using default line style and color
   plot(x, y, 'bo') # plot x and y using blue circle markers
   plot(y) # plot y using x as index array 0..N-1
   plot(y, 'r+') # ditto, but with red plusses
```

- Graph는 원래 figure 객체에 생성됨
- pyplot 객체 사용시, 기본 figure에 그래프가 그려짐

```
X_1 = range(100)
Y_1 = [np.cos(value) for value in X]

X_2 = range(100)
Y_2 = [np.sin(value) for value in X]

plt.plot(X_1, Y_1)
plt.plot(X_2, Y_2)
plt.show()
```




```
fig = plt.figure() # figure 반환
fig.set_size_inches(10,5) # 크기지정
ax_1 = fig.add_subplot(1,2,1) # 두개의 plot 생성
ax_2 = fig.add subplot(1,2,2) # 두개의 plot 생성
ax_1.plot(X_1, Y_1, c="b")^{100}
                                                          1.00
ax 2.plot(X 2, Y 2, c="g")0.75
                                                          0.75
plt.show() # show & flush 0.50
                                                          0.50
                               0.25
                                                          0.25
                               0.00
                                                          0.00
                              -0.25
                                                         -0.25
                              -0.50
                                                         -0.50
                                                         -0.75
                              -0.75
                                                         -1.00
                              -1.00
```

Set color

- Color 속성을 사용
- Float → 흑백, rgb color, predefined color 사용

```
plt.plot(X_1, Y_1, color="#eeefff")
plt.plot(X_2, Y_2, color="r")
plt.show()
```



Set linstyle

- Is 또는 linestyle 속성 사용

```
plt.plot(X_1, Y_1, c="b", linestyle="dashed")
plt.plot(X_2, Y_2, c="r", ls="dotted")
                                           200
plt.show()
                                           175
                                           150
                                           125
                                           100
                                            75
                                            50
                                            25
                                                   20
                                                              60
                                                                        100
```

Set title

- Pyplot에 title함수 사용, figure의 subplot별 입력 가능

```
plt.plot(X_1, Y_1, color="b", linestyle="dashed")
plt.plot(X_2, Y_2, color="r", linestyle="dotted")

plt.title("Two lines")
plt.show()
Two lines

plt.title("Two lines")
plt.show()
```


Set title

- Latex 타입의 표현도 가능 (수식 표현 가능)

```
plt.title('$y = \\frac{ax + b}{test}$')
                                                                     y = \frac{ax + b}{test}
plt.show()
                                               175
                                               150
                                               125
                                               100
                                                75
                                                50
                                                25
                                                            20
                                                                     40
                                                                             60
                                                                                     80
                                                                                             100
```

Set legend

- Legend 함수로 범례를 표시함, loc 위치등 속성 지정



Set grid & xylim

- Graph 보조선을 긋는 grid와 xy축 범위 한계를 지정

```
plt.grid(True, lw=0.4, ls="--", c=".90")
plt.xlim(-100, 200)
                                 200
plt.ylim(-200, 200)
                                 150
                                 100
                                  50
                                 -50
                                -100
                                                                    line 1
                                -150
                                -200
                                                      50
                                   -100
                                         -50
                                                           100
                                                                 150
                                                                        200
```

Matplotlib Graph

Scatter

- scatter 함수 사용, marker: scatter 모양지정

```
data 1 = np.random.rand(512, 2)
data 2 = np.random.rand(512, 2)
                                                          1.0
plt.scatter(data_1[:,0], data_1[:,1], c="b", marker="x")
plt.scatter(data_2[:,0], data_2[:,1], c="r", marker="^0)
plt.show()
                                                          0.6
                                                          0.4
                                                          0.2
                                                          0.0
                                                               0.0
                                                                      0.2
                                                                              0.4
                                                                                             0.8
```

Scatter

- s: 데이터의 크기를 지정, 데이터의 크기비교가능

```
N = 50
                                                    1.0
x = np.random.rand(N)
y = np.random.rand(N)
                                                    0.8
colors = np.random.rand(N)
area = np.pi * (15 * np.random.rand(N))**2
                                                    0.6
plt.scatter(x, y, s=area, c=colors, alpha=0.5)
plt.show()
                                                    0.4
                                                    0.2
                                                    0.0
                                                             0.2
                                                                    0.4
                                                                           0.6
                                                                                 0.8
                                                       0.0
```

Bar chart

```
50
                               40
 Bar 함수 사용
                               30
data = [[5., 25., 50., 20.],
        [4., 23., 51., 17],
                               10
        [6., 22., 52., 19]]
                                          1.0
                                             1.5
                                                 2.0
                                   0.0
X = np.arange(4)
plt.bar(X + 0.00, data[0], color = 'b', width = 0.25)
plt.bar(X + 0.25, data[1], color = 'g', width = 0.25)
plt.bar(X + 0.50, data[2], color = 'r', width = 0.25)
plt.xticks(X+0.25, ("A", "B", "C", "D"))
plt.show()
```

Bar chart

```
60
color list = ['b', 'g', 'r']
                                  20
data label = ["A", "B", "C"]
                                           0.5
                                               1.0
                                                  1.5
                                                      2.0
X = np.arange(data.shape[1])
                                       0.0
for i in range(data.shape[0]):
    plt.bar(X, data[i], bottom = np.sum(data[:i], axis=0),
             color = color list[i], label=data label[i])
plt.legend()
plt.show()
```

160


140

120

100

80

histogram



boxplot

```
data = np.random.randn(100,5)
plt.boxplot(data)
plt.show()
                      -1
                      -2
                      -3
```

matplotlib with pandas

- Pandas 0.7 버전이상 부터 matplotlib를 사용한 그래프 지원
- Dataframe, series별로 그래프 작성 가능

	CRIM	ZN	INDUS	CHAS	NOX	RM	AGE	DIS	RAD	TAX	PTRATIO	В	LSTAT	MEDV
0	0.00632	18.0	2.31	0	0.538	6.575	65.2	4.0900	1	296.0	15.3	396.90	4.98	24.0
1	0.02731	0.0	7.07	0	0.469	6.421	78.9	4.9671	2	242.0	17.8	396.90	9.14	21.6
2	0.02729	0.0	7.07	0	0.469	7.185	61.1	4.9671	2	242.0	17.8	392.83	4.03	34.7
3	0.03237	0.0	2.18	0	0.458	6.998	45.8	6.0622	3	222.0	18.7	394.63	2.94	33.4
4	0.06905	0.0	2.18	0	0.458	7.147	54.2	6.0622	3	222.0	18.7	396.90	5.33	36.2

Boston House Price Dataset

- 머신 러닝 등 데이터 분석을 처음 배울 때, 가장 대표적으로 사용하는 Example Dataset
- 1978년에 발표된 데이터로, 미국 인구통계 조사 결과 미국 보스턴 지역의 주택 가격에 영향 요소들을 정리함

http://lib.stat.cmu.edu/datasets/boston

Boston House Price Dataset

[01] CRIM 자치시(town) 별 1인당 범죄율 ΖN 25,000 평방피트를 초과하는 거주지역의 비율 비소매상업지역이 점유하고 있는 토지의 비율 [03] INDUS 찰스강에 대한 더미변수(강의 경계에 위치한 경우는 1, 아니면 0) [04] CHAS 10ppm 당 농축 일산화질소 [05] NOX X 변수 주택 1가구당 평균 방의 개수 [06] RM 13개 [07] AGE 1940년 이전에 건축된 소유주택의 비율 5개의 보스턴 직업센터까지의 접근성 지수 [08] DIS [09] RAD 방사형 도로까지의 접근성 지수 10,000 달러 당 재산세율 [10] TAX 자치시(town)별 학생/교사 비율 [11] PTRATIO 1000(Bk-0.63)^2, 여기서 Bk는 자치시별 흑인의 비율을 말함. [12] B [13] LSTAT 모집단의 하위계층의 비율(%) Y 변수 [14] MEDV 본인 소유의 주택가격(중앙값) (단위: \$1,000)

http://www.dator.co.kr/ctg258/textyle/1721307

http://www.cs.toronto.edu/~delve/data/boston/bostonDetail.html

- 데이터간의 상관관계를 볼 때 scatter graph 사용 가능

```
fig = plt.figure()
ax = []
for i in range(1,5):
    ax.append(fig.add_subplot(2,2,i))
ax[0].scatter(df data["CRIM"], df data["MEDV"])
ax[1].scatter(df_data["PTRATIO"], df_data["MEDV"])
                                                                        20
ax[2].scatter(df data["AGE"], df data["MEDV"])
ax[3].scatter(df data["NOX"], df data["MEDV"])
plt.show()
                                                                                       20.0
                                                                                           22.5
                                                                        20
                                                                                        0.8
```

- matplotlib의 꾸미기 함수 그대로 사용함

```
ax[0].scatter(df data["CRIM"], df data["MEDV"], color="b", label="CRIM")
ax[1].scatter(df_data["PTRATIO"], df_data["MEDV"], color="g"
ax[2].scatter(df data["AGE"], df data["MEDV"] )
                                                            CRIM
ax[3].scatter(df_data["NOX"], df_data["MEDV"]) 50 +
plt.subplots_adjust(wspace=0, hspace=0)
                                                  40
ax[0].legend()
                                                                      30
                                                  30
ax[0].set title("CRIM")
                                                  20
                                                                      20
                                                  10
                                                  50
                                                  40
                                                  30
                                                  20
                                                  10
                                                                                 0.6
                                                                                        0.8
                                                                      100
```

- plot 함수를 사용하면 전체 데이터의 graph를 그림

df_data.plot()






fig = plt.figure()



House price MEDV




Scaled boxplot

```
from sklearn.preprocessing import StandardScaler
               std scaler = StandardScaler()
               scale data = std scaler.fit transform(df data)
               fig = plt.figure()
               ax = fig.add subplot(1,1,1)
               ax.boxplot(scale data, labels=df data.columns)
               fig.set size inches(18.5, 10.5)
CRIM
        INDUS
            CHAS
                 NOX
                     RM
                         AĠE
                             DIS
                                  RAD
                                      TAX
                                         PTRATIO
                                                  LSTAT
                                                       MEDV
```

Scatter matrix

```
pd.scatter_matrix(df_data, diagonal="kde", alpha=1, figsize=(20, 20))
plt.show()
```



Scatter matrix

```
fig = plt.figure()
ax = fig.add subplot(111)
                                                                                                             - 1.00
cax = ax.matshow(corr_data, vmin=-1, vmax=1,
                                                          interpolation='nearest')
fig.colorbar(cax)
                                                                 CRIM ZN INDUS CHAS NOX RM AGE DIS RAD TAXPTRATIO B LSTATMEDV
fig.set_size_inches(10,10)
                                                              CRIM
                                                                                                             0.75
ticks= np.arange(0,14,1)
                                                              ΖN
ax.set_xticks(ticks)
                                                             INDUS
                                                                                                             0.50
ax.set_yticks(ticks)
                                                             CHAS :
                                                              NOX
ax.set xticklabels(df data.columns)
                                                                                                             - 0.25
                                                              RM
ax.set yticklabels(df data.columns)
                                                              AGE :
                                                                                                             - 0.00
                                                              DIS -
                                                              RAD
                                                                                                             -0.25
                                                              TAX
                                                            PTRATIO
                                                                                                             -0.50
                                                             LSTAT
                                                                                                             -0.75
                                                             MEDV
```